

París 2024 • Medallistas Olímpicos

Luis García Díaz





Objetivo del Proyecto

Transformar datos crudos de Kaggle sobre los Juegos Olímpicos de París 2024 en un modelo dimensional listo para análisis y visualización BI.

Fuente

Stage externo en Snowflake con datos de **2.202 medallas** olímpicas extraídas de Kaggle

Stack


Snowflake · dbt ·
Arquitectura Medallion
(Bronze → Silver → Gold)

Resultado

Modelo estrella **desnormalizado**, sin JOINS adicionales, listo para dashboards BI

Arquitectura Medallion

Tres capas independientes, cada una en su propia base de datos en Snowflake, con responsabilidades claramente delimitadas.



Cada capa vive en su propia base de datos: **BRONZE_DB** • **SILVER_DB** • **GOLD_DB** – garantizando aislamiento, trazabilidad y control de acceso granular por entorno.



CAPA 1

Bronze • Ingesta Cruda

Sin casteos, sin transformaciones. Todos los valores se almacenan como `VARCHAR` preservando la fuente original.

bronze_medalists_raw

2.202 filas · 1 fila por atleta × evento × medalla · Fuente única para Silver y Gold

Silver • 9 Tablas Normalizadas

Normalización, tipado estricto e integridad referencial. Cada entidad tiene su propia tabla con registros comodín para valores desconocidos.

Modelo	Filas	Descripción
silver_medalla	2.202	Tabla de hechos con surrogate key MD5
silver_atleta	1.949	Atletas únicos deduplicados
silver_pais	91	Países + comodín "País Desconocido"
silver_delegacion	~91	Delegaciones olímpicas
silver_lugar	~1.520	Lugares de nacimiento con coordenadas
silver_region_nuts	~640	Jerarquía NUTS europea (niveles 0 - 3)
silver_evento	325	Eventos olímpicos
silver_disciplina	~47	Disciplinas por deporte
silver_deporte	~32	Deportes olímpicos

CAPA 3

Gold • Modelo Dimensional BI-Ready

Cinco modelos desnormalizados listos para consumo directo. Sin **JOINS adicionales** necesarios para construir cualquier dashboard.



fact_medalla

2.202 filas · IDs + nombres de evento, disciplina, deporte y jerarquía NUTS completa

dim_pais

91 países con medallas oro / plata / bronce pre-agregadas

dim_atleta

1.949 atletas con lugar, coordenadas y NUTS3 desnormalizados

dim_evento

325 eventos con disciplina y deporte aplanados

dim_nuts

~445 regiones · Jerarquía NUTS3 → NUTS0 desnormalizada

Calidad de Datos • Lo que Sabemos

El pipeline es transparente sobre sus limitaciones. Las gaps de cobertura están documentadas y son tratables por los consumidores.

1

Fechas de nacimiento

17 atletas sin `fecha_nacimiento` – valor `NULL` en Silver y Gold

2

Lugar de nacimiento

93 atletas sin lugar de nacimiento registrado en Kaggle data

3

Cobertura NUTS

~56% de medallas sin datos NUTS – atletas no europeos → `id_nuts3 = NULL`

4

Refugiados y AIN

Acreditados a `'N/A'` / "País Desconocido" · Filtrar con `es_pais_conocido = TRUE`

⚠ **2 advertencias conocidas (severity: warn)** que no interrumpen el pipeline: `not_null_silver_lugar_nombre` (lugares sin topónimo en Kaggle) y `not_null_silver_delegacion_wikidata_id_pais` (Equipo de Refugiados sin país asignado).

El Dataset **en Cifras**

2.202

Medallas totales

Registros en la fact table

1.949

Atletas únicos

Deduplicados en Silver

91

Países / delegaciones

Incluyendo comodín

325

Eventos olímpicos

Modelados en dim_evento

44%

Cobertura NUTS

Atletas europeos con región

95

Tests dbt

93 passing · 2 warn · 0 errors

Stack Tecnológico



Snowflake

Data warehouse en la nube. Stage externo para ingesta, función personalizada `PARSE_CSV_LINE` y bases de datos separadas por capa.



dbt

Transformación, testing automatizado (95 tests), documentación y linaje completo generado con `dbt docs`.



Kaggle

Fuente de datos abierta. Dataset de medallistas de los Juegos Olímpicos de París 2024 con 2.202 registros.



NUTS / Eurostat

Jerarquía geográfica europea NUTS 0 - 3 para enriquecer atletas con región, país y datos socioeconómicos.

Datos Listos para **Análisis**

De datos crudos de Kaggle a un modelo dimensional en Snowflake, con trazabilidad completa, 95 tests automatizados y documentación generada con dbt docs.

"Cada medalla, cada atleta, cada región – **modelados con precisión.**"

Bronze

Ingesta fiel a la fuente

Silver

9 tablas normalizadas

Gold

Modelo estrella BI-ready

